Escuela de Actuaría

Administración actuarial de riesgos

Dr. Francisco García Castillo

Temario

II. Administración del riesgo de crédito

1. Administración del Riesgo de crédito
2. Determinación de insumos
   a. La probabilidad de incumplimiento
      i. Agencias calificadoras
      ii. Modelo de Merton
      iii. Z-Altman
      iv. Econométricos:
         a. MPL
         b. Logit
         c. Probit
   b. La severidad
3. Matrices de transición
   a. Modelos de cartera de bonos (CreditMetrics)

Introducción

En el estudio de la determinación de las probabilidades de incumplimiento dentro del riesgo de crédito se han desarrollado los modelos econométricos con gran éxito.

El objetivo de esta presentación es dar una breve descripción de la teoría subyacente del modelo de probabilidad lineal, del modelo logit y el modelo probit.

Modelo lineal de probabilidad (MLP)

Para establecer las ideas, considere el siguiente modelo econométrico:

$$Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$$

Donde:

$X =$ el ingreso familiar

$Y = 0$ ó 1 (si la familia tiene casa propia 1, si la familia no tiene casa propia, es 0).

Este modelo parece un modelo de regresión lineal común, pero debido a que la variable regresada es binaria (o dicótoma), se denomina **modelo lineal de probabilidad** (MLP).

Esto es porque la esperanza condicionada de Y_i dado X_i, $E[Y_i|X_i]$, se interpreta como la probabilidad condicional de que el suceso tenga lugar dado X_i; es decir, $\Pr(Y_i = 1|X_i)$.

Modelo lineal de probabilidad (MLP)

Dada la ecuación $Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$, $E[Y_i|X_i]$ es la probabilidad que una familia tenga casa propia y perciba ingresos por una cierta cantidad X_i.

La justificación del nombre MLP es la siguiente:

Asumiendo que $E[\varepsilon_i] = 0$, entonces:

$$E[Y_i|X_i] = \beta_1 + \beta_2 X_i$$

- P_i es la probabilidad que $Y_i = 1$ (es decir, de que el suceso ocurra)
- $(1 - P_i)$ es la probabilidad que $Y_i = 0$ (es decir, de que el suceso no ocurra)
- La variable Y_i tiene la siguiente distribución de probabilidad:

Y_i	Probabilidad
0	$1 - P_i$
1	P_i
Total	1

Es decir, $Y_i \sim Bernoulli$, y su valor esperado es:

$$E[Y_i] = 0(1 - P_i) + 1P_i = P_i.$$

Modelo lineal de probabilidad (MLP)

Igualando las dos esperanzas se obtiene:

$$E[Y_i|X_i] = E[Y_i]$$

$$\beta_1 + \beta_2 X_i = P_i$$

Es decir, la esperanza condicional del modelo se interpreta como la probabilidad condicionada de Y_i.

Observe que si existen n intentos independientes, cada intento con una probabilidad p de éxito y una probabilidad $(1 - p)$ de fracaso, y si

$X = \{\# \, de \, éxitos\}$

Entonces $X \sim Bin(n, p)$, con media np y varianza $np(1 - p)$.

Modelo lineal de probabilidad (MLP)

Inconvenientes del MLP:

- No normalidad de las perturbaciones ε_i, porque $\varepsilon_i \sim Bernoulli(p)$.
  - Este inconveniente no es tan crítico porque las estimaciones puntuales de MCO aún permanecen insesgadas; y se demuestra que, conforme el tamaño de la muestra aumenta indefinidamente, los estimadores de MCO tienden a tener una distribución normal.

    Por consiguiente, en muestras grandes, la inferencia estadística del MLP seguirá el procedimiento de MCO usual según el supuesto de normalidad.

Modelo lineal de probabilidad (MLP)

- Varianzas heteroscedásticas de las perturbaciones, ya que $Var(\varepsilon_i) = P_i(1 - P_i)$
  - Para resolver este inconveniente, dado que $Var(\varepsilon_i)$ depende de $E[Y_i|X_i]$, se divide ambos lados del modelo $Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$ entre $\sqrt{w_i} = \sqrt{P_i(1 - P_i)}$:

$$\frac{Y_i}{\sqrt{w_i}} = \frac{\beta_1}{\sqrt{w_i}} + \beta_2 \frac{X_i}{\sqrt{w_i}_i} + \frac{\varepsilon_i}{\sqrt{w_i}}$$

Bajo esta transformación, el término de error transformado es homoscedástico.

Por consiguiente, después de estimar el modelo inicial, se estima la transformada mediante MCO, lo cual no es otra cosa que los mínimos cuadrados ponderados (MCP), donde w_i son las ponderaciones.

Modelo lineal de probabilidad (MLP)

En la práctica se desconoce $E[Y_i|X_i]$, por lo que se desconocen los ponderadores w_i. Para ello, se realiza el procedimiento siguiente:

- **Paso 1**. Realizar la regresión $Y_i = \beta_1 + \beta_2 X_i + \varepsilon_i$ por MCO sin considerar el problema de heteroscedasticidad y obtener $\hat{Y}_i$, que es el valor estimado de $E[Y_i|X_i]$.

  Luego, determinar $\widehat{w}_i = \hat{Y}_i\left(1 - \hat{Y}_i\right)$.

- **Paso 2**. Transformar los datos como $\frac{Y_i}{\sqrt{w_i}} = \frac{\beta_1}{\sqrt{w_i}} + \beta_2 \frac{X_i}{\sqrt{w_i}_i} + \frac{\varepsilon_i}{\sqrt{w_i}}$, y

- **Paso 3.** Estimar la ecuación transformada mediante MCO (es decir, mínimos cuadrados ponderados).

Para muestras grandes, se utilizan los errores estándar corregidos por heteroscedasticidad de White.

Modelo lineal de probabilidad (MLP)

- No cumplimiento de $0 \leq E[Y_i|X_i] \leq 1$
  - MCO no toma en cuenta la restricción $0 \leq E[Y_i|X_i] \leq 1$, por lo que hay dos formas de establecer que $\hat{Y}_i$ se encuentre entre 0 y 1:
    1. Estimar el MLP mediante el método usual de MCO y determinar si el $\hat{Y}_i$ estimado se encuentra entre 0 y 1. Si algunos valores son menores que 0, para esos casos se supone que $\hat{Y}_i = 0$; si son mayores que 1, se supone que $\hat{Y}_i = 1$.
    2. Diseñar una técnica de estimación que garantice que las probabilidades condicionales estimadas $\hat{Y}_i$ se encuentren entre 0 y 1. Los Modelos Logit y Probit garantizarán que las probabilidades estimadas se encuentren entre los límites lógicos 0 y 1.

Modelo lineal de probabilidad (MLP)

- Valor cuestionable de R^2 como medida de la bondad del ajuste, ya que en la mayoría de las aplicaciones prácticas, R^2 se encuentra entre 0.2 y 0.6

Modelo lineal de probabilidad (MLP)

Laboratorio. La Tabla 15.1 muestra datos sobre la propiedad de vivienda Y (1=tiene casa propia, 0=no tiene casa propia) e ingreso familiar X (miles de USD) para una muestra de 40 familias.

1. Con base en esta información, obtenga el Modelo Lineal de Probabilidad por MCO. Interprete resultados.
2. Estime el ponderador que hace homocedástica la regresión. Obtenga MCO nuevamente.

Ejemplo MLP

Modelo lineal de probabilidad (MLP)

Laboratorio. Trece aspirantes a un programa de posgrado obtuvieron las calificaciones cuantitativa y verbal en el examen GRE que se presentan en la **Tabla 15.23**. Seis estudiantes fueron admitidos en el programa.

a) Con el modelo MLP, pronostique la probabilidad de admisión al programa con base en las calificaciones cuantitativas y verbales del GRE.

b) ¿Es un modelo satisfactorio? De no ser así, ¿qué alternativa(s) ofrece?

Modelo lineal de probabilidad (MLP)

Núm. de estudiante	Cuantitativo, *Q*	Verbal, *V*	Admitido al programa de posgrado (Sí 1, No 0)
1	760	550	1
2	600	350	0
3	720	320	0
4	710	630	1
5	530	430	0
6	650	570	0
7	800	500	1
8	650	680	1
9	520	660	0
10	800	250	0
11	670	480	0
12	670	520	1
13	780	710	1

TABLA 15.23. Calificaciones del examen GRE.

Alternativas al MLP: los modelos Logit y Probit

Si bien el MLP podría verse bastante intuitivo, presenta diversos inconvenientes:

- No normalidad de los ε_i.
- Heteroscedasticidad de ε_i.
- $\hat{Y}_i$ se encuentre fuera del rango 0-1, y
- Valores bajos de R^2.

Si bien estos inconvenientes son superables[1/], el problema fundamental del MLP es que no es un modelo realista en la estimación de probabilidades porque supone que $P_i = E[Y_i|X_i] = \beta_1 + \beta_2 X_i$ aumenta linealmente con X; i.e., el efecto marginal de X es constante.

[1/] Incrementar el tamaño de muestra y reducir así el problema de la no normalidad; aplicar MCP para resolver el problema de heteroscedasticidad; y hacer que las probabilidades estimadas se encuentren dentro del intervalo 0-1.

Alternativas al MLP: los modelos Logit y Probit

En el ejemplo de la propiedad de vivienda se encontró que, a medida que X aumentaba en USD $1,000 mensuales, la probabilidad de ser propietario de una casa aumentaba en 10%, independientemente del nivel de ingreso. En la realidad, esto no sucede.

Lo que en verdad se espera es que P_i estuviera relacionado en forma **no lineal** con X_i*:* con ingresos muy bajos, una familia no será propietaria de una casa, pero en niveles altos de ingresos, por ejemplo, a partir de X^*, es muy probable que sí tenga casa propia.

Alternativas al MLP: los modelos Logit y Probit

Cualquier incremento en el ingreso más allá de X^* tendría un efecto pequeño sobre la probabilidad de tener casa propia.

Así, en ambos extremos de la distribución de ingresos, la probabilidad de ser dueño de una casa prácticamente no se verá afectada por un pequeño incremento en X.

Alternativas al MLP: los modelos Logit y Probit

Por consiguiente, se requiere de un modelo probabilístico que tenga las siguientes características:

- A medida que aumente X_i, $P_i = E[Y = 1|X]$ también aumente pero nunca se salga del intervalo 0-1, y
- La relación entre P_i y X_i sea no lineal, es decir, "*uno se acerca a cero con tasas cada vez más lentas a medida que se reduce X_i, y se acerca a uno con tasas cada vez más lentas a medida que X_i se hace muy grande*".

En términos geométricos, el modelo que deseamos tendría la forma de la figura 15.2.

Alternativas al MLP: los modelos Logit y Probit

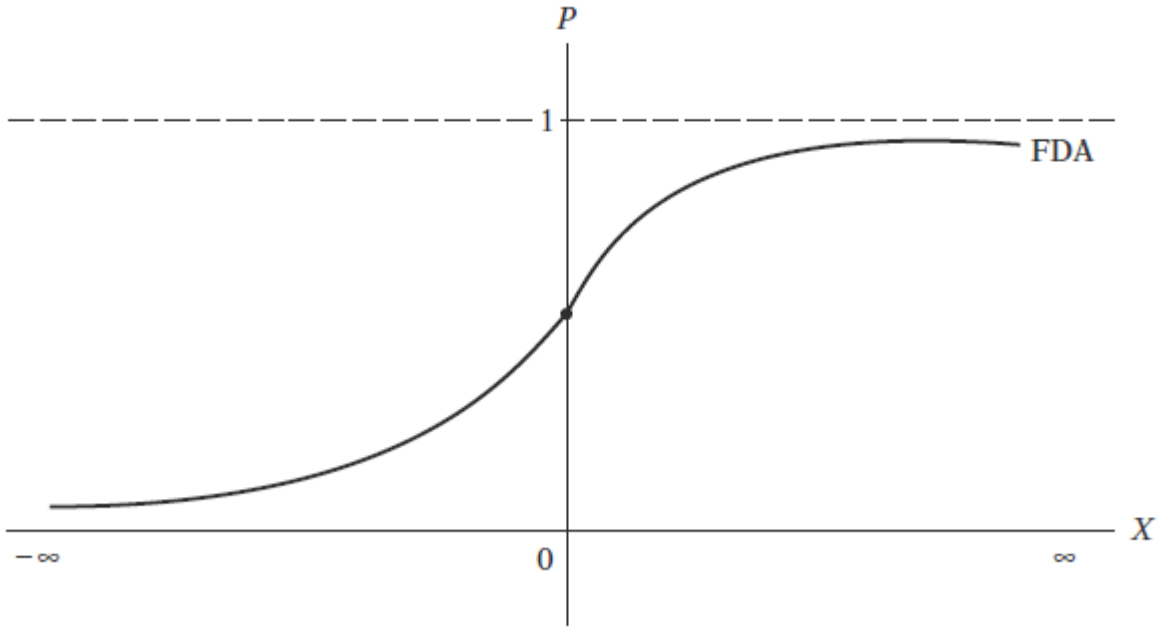

FIGURA 15.2 Función de distribución acumulativa (FDA).

Se observa que la probabilidad se encuentra entre 0 y 1, y que éste varía en forma no lineal con *X*.

Esta curva en forma de S se parece mucho a la **función de distribución acumulativa** de una variable aleatoria (FDA).

Alternativas al MLP: los modelos Logit y Probit

Por consiguiente, se puede utilizar fácilmente la FDA en regresiones de modelos en los cuales la variable de respuesta es dicótoma, para adquirir valores 0-1.

La pregunta es, ¿cuál FDA?

Aunque todas las FDA tienen forma de S, para cada variable aleatoria hay una FDA única. Por razones tanto históricas como prácticas, las FDA que suelen seleccionarse para representar los modelos de respuesta 0-1 son:

- La logística, y
- La normal.

La primera da lugar al modelo **logit**, y la segunda al modelo **probit** o **normit**.

El modelo Logit

En riesgo de crédito, durante la década de 1980s, el método de análisis discriminante de Altman fue reemplazado por los modelos logit y probit, los cuales han sido muy populares para el pronóstico de incumplimientos de pago y quiebras de empresas.

De hecho, la regulación bancaria pide un modelo Logit para la determinación de las probabilidades de incumplimiento por parte de los acreditados.

A continuación de ofrece una breve descripción de estos modelos para comprender las estimaciones de las PD.

El modelo Logit

Dando seguimiento al ejemplo de propiedad de vivienda en relación con el ingreso, el MLP fue:

$$P_i = \beta_1 + \beta_2 X_i$$

Donde X_i es el ingreso de la familia y $P_i = E[Y = 1|X]$ significa que la familia es propietaria de una casa.

El modelo Logit

Considere ahora la siguiente representación de la propiedad de vivienda:

$$P_i = \frac{1}{1 + e^{-(\beta_1 + \beta_2 X_i)}}$$

Que con fines de facilitar la notación, se sustituye $\beta_1 + \beta_2 X_i = Z_i$, así queda entonces:

$$P_i = \frac{1}{1 + e^{-(\beta_1 + \beta_2 X_i)}} = \frac{1}{1 + e^{-Z_i}} = \frac{1}{1 + \frac{1}{e^{Z_i}}} = \frac{1}{\frac{e^{Z_i} + 1}{e^{Z_i}}} = \frac{e^{Z_i}}{e^{Z_i} + 1} = \frac{e^{Z_i}}{1 + e^{Z_i}}$$

Esta ecuación se conoce como función de distribución logística.

Observación: dado que $Z_i \in (-\infty, \infty)$, P_i está en el intervalo $(0,1)$. Además, P_i está relacionada de una manera no lineal con Z_i (es decir, con X_i).

El modelo Logit

Si la probabilidad de tener casa propia está dada por $P_i = \frac{e^{Z_i}}{1+e^{Z_i}}$, entonces $1 - P_i$, la probabilidad de no tener casa propia, es:

$$1 - P_i = 1 - \frac{e^{Z_i}}{1 + e^{Z_i}}$$

$$= \frac{1 + e^{Z_i}}{1 + e^{Z_i}} - \frac{e^{Z_i}}{1 + e^{Z_i}}$$

$$= \frac{1}{1 + e^{Z_i}}$$

Entonces, si obtenemos el momio $\frac{P_i}{1-P_i}$:

$$\frac{P_i}{1 - P_i} = \frac{\frac{e^{Z_i}}{1 + e^{Z_i}}}{\frac{1}{1 + e^{Z_i}}} = \frac{e^{Z_i}(1 + e^{Z_i})}{1 + e^{Z_i}} = e^{Z_i}$$

$\frac{P_i}{1-P_i}$ es la **razón de las probabilidades (o momios)** en favor de tener una casa propia: si $P_i = 0.8$, entonces las posibilidades son 4 a 1 en favor de que la familia posea una casa propia.

El modelo Logit

Tomando el logaritmo natural de $\frac{P_i}{1-P_i}$, se obtiene:

$$
\begin{aligned}
L_i &= ln\left(\frac{P_i}{1-P_i}\right) \\
&= ln(e^{Z_i}) \\
&= Z_i \\
&= \beta_1 + \beta_2 X_i
\end{aligned}
$$

Mediante esta transformación se establece una relación lineal entre β y X con L_i, el logaritmo de la razón de las probabilidades.

L_i se llama el **logit de la regresión**, y de aquí el nombre **modelo logit**.

El modelo Logit

Características del modelo logit:

- A medida que P va de 0 a 1 (es decir, a medida que Z varía de $-\infty$ a $+\infty$, el logit L va de $-\infty$ a $+\infty$.
- Aunque L es lineal en X, las probabilidades no lo son[2–/].
- Se pueden añadir tantas regresoras como indique la teoría subyacente.
- Si L, el logit, es positivo, significa que cuando se incrementa el valor de la(s) regresora(s), aumentan las posibilidades de que la regresada sea igual a 1; y si L es negativo, las posibilidades de que la regresada iguale a 1 disminuyen conforme se incrementa el valor de X.

[2–/] Se demuestra que $^{dP}/_{dX} = \beta_2 P(1-P)$, lo cual implica que la tasa de cambio de la probabilidad respecto de X contiene no sólo a β_2, sino también al nivel de probabilidad a partir del cual se mide el cambio.

El modelo Logit

- La interpretación del modelo $L_i = ln\left(\frac{P_i}{1-P_i}\right) = \beta_1 + \beta_2 X_i$ es:
  - β_2 mide el cambio en L ocasionado por un cambio unitario en X.

    En el ejemplo, nos dice cómo cambia el logaritmo de las posibilidades en favor de tener una casa propia a medida que el ingreso cambia en una unidad, por ejemplo, USD $1,000.
  - El intercepto β_1 es el valor del logaritmo de las posibilidades en favor de tener una casa propia si el ingreso es cero.

    Al igual que la mayoría de las interpretaciones de los interceptos, esta interpretación puede no tener significado físico alguno.

El modelo Logit

- Con un nivel determinado de ingreso, por ejemplo, X^*, si se desea estimar la probabilidad de tener una casa propia y no las posibilidades en favor de tener una casa propia, se hace con $P_i = \frac{e^{Z_i}}{1+e^{Z_i}}$ una vez que se han determinado β_1 y β_2.
- Mientras que el MLP supone que P_i está linealmente relacionado con X_i, el modelo logit supone que el logaritmo de la razón de probabilidades está relacionado linealmente con X_i.

El modelo Logit: Estimación

La estimación de los parámetros del modelo

$$L_i = ln\left(\frac{P_i}{1 - P_i}\right) = \beta_1 + \beta_2 X_i + \varepsilon_i$$

Requiere, además de X_i, los valores de la regresada, o del logit, L_i. Esto depende del tipo de datos que se analicen, los cuales se clasifican en:

- Datos agrupados.
- Datos de nivel individual.

El modelo Logit: Estimación

Datos agrupados o duplicados. Considere los datos de la tabla siguiente, la cual proporciona datos agrupados (observaciones repetidas) sobre diversas familias, de acuerdo con el nivel de ingreso y el número de familias que tienen casa propia en cada nivel de ingreso.

Correspondiente a cada nivel de ingreso X_i, hay N_i familias, de las cuales n_i tienen casa propia ($n_i \leq N_i$). Se determina

$$\hat{P}_i = \frac{n_i}{N_i}$$

es decir, la frecuencia relativa, la cual se utiliza como una estimación de la verdadera P_i correspondiente a cada X_i.

X Miles de USD	N_i	n_i
6	40	8
8	50	12
10	60	18
13	80	28
15	100	45
20	70	36
25	65	39
30	50	33
35	40	30
40	25	20

El modelo Logit: Estimación

Si N_i es relativamente grande, $\hat{P}_i$ será una estimación razonablemente buena de P_i.

Con $\hat{P}_i$ se obtiene el logit como:

$$\hat{L}_i = ln\left(\frac{\hat{P}_i}{1-\hat{P}_i}\right)$$
$$= \hat{\beta}_1 + \hat{\beta}_2 X_i$$

Que es una buena estimación del verdadero logit L_i, si el número de observaciones N_i en cada nivel X_i es razonablemente grande.

En resumen, con la información *agrupada* se puede obtener información sobre la variable dependiente, los logit, para estimar el modelo

$$\hat{L}_i = ln\left(\frac{\hat{P}_i}{1-\hat{P}_i}\right) = \hat{\beta}_1 + \hat{\beta}_2 X_i$$

El modelo Logit: Estimación

Para aplicar MCO a la ecuación $\hat{L}_i = ln\left(\frac{\hat{P}_i}{1-\hat{P}_i}\right) = \hat{\beta}_1 + \hat{\beta}_2 X_i$ en la estimación de los parámetros, debe seguirse el proceso siguiente:

- Para cada nivel de ingreso X_i, determinar la probabilidad estimada de tener una casa propia como $\hat{P}_i = \frac{n_i}{N_i}$
- Para cada X_i, obtener el Logit siguiente:

$$\hat{L}_i = ln\left(\frac{\hat{P}_i}{1-\hat{P}_i}\right)$$

El modelo Logit: Estimación

- Se resuelve el problema de heteroscedasticidad del modelo $L_i = ln\left(\frac{P_i}{1-P_i}\right) = \beta_1 + \beta_2 X_i + \varepsilon_i$ con la siguiente transformación:

$$\sqrt{w_i}L_i = \sqrt{w_i}\beta_1 + \sqrt{w_i}\beta_2 X_i + \sqrt{w_i\varepsilon_i}$$

$$L_i^* = \sqrt{w_i}\beta_1 + \beta_2 X_i^* + v_i$$

Donde:

$w_i = N_i\hat{P}_i\left(1 - \hat{P}_i\right)$

L_i^* es la transformada o ponderada L_i;

X_i^* es la transformada o ponderada de X_i, y

v_i es el término de error transformado.

Se verifica que el término de error transformado v_i es homoscedástico, y la varianza de error original es $\sigma_\varepsilon^2 = \frac{1}{N_i\hat{P}_i(1-\hat{P}_i)}$.

El modelo Logit: Estimación

- Estimar mediante MCO el modelo

  $$\sqrt{w_i}L_i = \sqrt{w_i}\beta_1 + \sqrt{w_i}\beta_2 X_i + \sqrt{w_i\varepsilon_i}$$

  Recuerde que MCP es MCO aplicado sobre los datos transformados. Observe que no hay término de intercepto introducido explícitamente. Por consiguiente, se estima mediante el procedimiento de regresión a través del origen.

- Establecer los intervalos de confianza y/o pruebas de hipótesis dentro del marco usual de MCO, teniendo en mente que las conclusiones serán válidas solo si la muestra es razonablemente grande. Por consiguiente, en muestras pequeñas, los resultados estimados deben interpretarse con cautela.

El modelo Logit: Estimación

Ejemplo. Utilicemos el modelo logit agrupado o glogit. Los resultados de la regresión con mínimos cuadrados ponderados (15.6.7) que se basa en los datos de la tabla 15.5 son los siguientes:

Ejemplo LOGIT

X Miles de USD	N_i	n_i
6	40	8
8	50	12
10	60	18
13	80	28
15	100	45
20	70	36
25	65	39
30	50	33
35	40	30
40	25	20

Modelos Logit y Probit

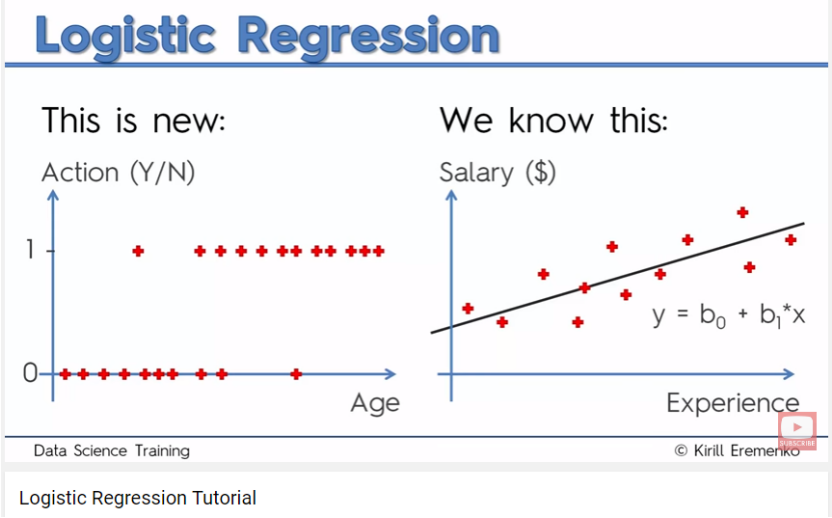

Para una plática sobre este tema pueden verse los siguientes videos: https://www.youtube.com/watch?v=nz-FrbAa8dY

Y para aplicaciones en las probabilidades de incumplimiento: https://www.youtube.com/watch?v=HnQ6QjeGMm0&t=101s

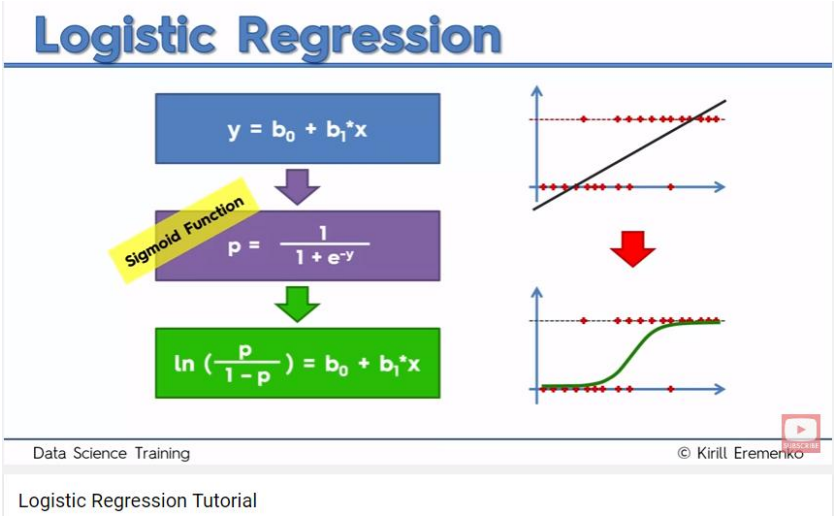

El modelo Logit: Estimación

Regulación. CUB

Artículo 91 Bis 1.- La Probabilidad de Incumplimiento de los créditos clasificados como "B, A, N, P u O" conforme al Artículo 91 Bis de las presentes disposiciones, se determinará de acuerdo con las fracciones I a V siguientes, según corresponda:

I. La Probabilidad de Incumplimiento de los créditos de la ***Cartera Crediticia de Consumo no Revolvente*** clasificados como "B" deberá obtenerse conforme a lo siguiente:

a) Si $ATR_i^B > 3$ o cuando el crédito se encuentre en cartera vencida de acuerdo con los términos establecidos en el criterio B-6 "Cartera de Crédito" de los Criterios Contables, entonces:

$$PI_i^B = 100\%$$

El modelo Logit: Estimación

b) Si $ATR_i^B \leq 3$, entonces:

$$PI_i^B = \frac{1}{1 + e^{-z_i^B}}$$

Donde:

$$z_i^B = \beta_0^B + \sum_{j=1}^{7} \beta_j^B \times VAR_{ij}^B$$

Coeficiente	Valor
β_0^B	-2.5456
β_1^B	2.2337
β_2^B	1.0526
β_3^B	0.4361
β_4^B	0.0780
β_5^B	-0.5141
β_6^B	-0.0152
β_7^B	-0.0672

El modelo Logit: Estimación

- $VAR_{i1}^{B} = ATR_{i}^{B}$: # de atrasos del i-ésimo crédito observados a la fecha de calificación.
- $VAR_{i2}^{B} = \%SDOIMP_{i}^{B}$: % que representa el Saldo del Crédito del $i-ésimo$ crédito a la fecha de calificación respecto al Importe Original del Crédito.
- $VAR_{i3}^{B} = Medio_{i}^{B}$: 1 Si el Monto a Pagar es mayor a $634 y $VECES_{i}^{B}$ es menor o igual a 2; O en otro caso. Donde $VECES_{i}^{B}$ se calcula como el Monto a Pagar Reportado a las sociedades de información crediticia dividido entre el Monto a Pagar a la Institución.
- $VAR_{i4}^{B} = Medio_{i}^{B}$: 1 Si el Monto a Pagar es mayor a $634 y $VECES_{i}^{B}$ es menor o igual a 2; O en otro caso.
- $VAR_{i5}^{B} = BAJO_{i}^{B}$: 1 Si el Monto a Pagar es menor a $634; O en otro caso.
- $VAR_{i6}^{B} = ANT_{i}^{B}$: Antigüedad del Acreditado en la Institución de que se trate expresada en meses.
- $VAR_{i7}^{B} = MESES_{i}^{B}$: Meses transcurridos desde el último atraso mayor a un día en los últimos 13 meses, incluyendo el mes en el que se realiza la calificación del crédito correspondiente.

  Para determinar dichos meses, se deberán considerar todos los compromisos crediticios del acreditado registrados en la totalidad de las sociedades de información crediticia. En caso de que existan más de 13 meses transcurridos desde el último atraso esta variable tomará el valor de trece.

El modelo Logit: Estimación

Sustituyendo, si $ATR_i^B \leq 3$, entonces:

Coeficiente	Valor
β_0^B	-2.5456
β_1^B	2.2337
β_2^B	1.0526
β_3^B	0.4361
β_4^B	0.0780
β_5^B	-0.5141
β_6^B	-0.0152
β_7^B	-0.0672

$$PI_i^B = \frac{1}{1+e^{-z_i^B}}$$

$$= \frac{1}{1+e^{-\left(\beta_0^B + \sum_{j=1}^{7} \beta_j^B \times VAR_{ij}^B\right)}}$$

$$= \frac{1}{1+e^{-\left(\beta_0^B + \beta_1^B \cdot VAR_{i1}^B + \beta_2^B \cdot VAR_{i2}^B + \beta_3^B \cdot VAR_{i3}^B + \beta_4^B \cdot VAR_{i4}^B + \beta_5^B \cdot VAR_{i5}^B + \beta_6^B \cdot VAR_{i7}^B + \beta_7^B \cdot VAR_{i7}^B\right)}}$$

$$= \frac{1}{1+e^{2.5456 - 2.2337 \cdot VAR_{i1}^B - 1.0526 \cdot VAR_{i2}^B - 0.4361 \cdot VAR_{i3}^B - 0.0780 \cdot VAR_{i4}^B + 0.5141 \cdot VAR_{i5}^B + 0.0152 \cdot VAR_{i6}^B + 0.0672 \cdot VAR_{i7}^B}}$$

de atrasos del i-ésimo crédito observados a la fecha de calificación.

% que representa el Saldo del Crédito del $i-$ésimo crédito a la fecha de calificación respecto al Importe Original del Crédito

1 si Monto a Pagar < \$634 y $VECES_i^B \leq 2$; O en otro caso.

1 Si el Monto a Pagar < \$634; O en otro caso.

Antigüedad del Acreditado en la Institución de que se trate expresada en meses

Meses transcurridos desde el último atraso mayor a un día en los últimos 13 meses.

Escuela de Actuaría

Administración actuarial de riesgos

Dr. Francisco García Castillo